

Projeto Inteligência Artificial e Data Science



Smoking Status Predictor

Sistema de predição de status de fumante (**Never Smoked**, **Former Smoker** ou **Current Smoker**) utilizando Machine Learning com XGBoost treinado sobre o dataset da Korean National Health Insurance Service (NHIS).



Visão Geral

O projeto utiliza indicadores biométricos para prever o status de tabagismo de um paciente.

Tecnologias Utilizadas

Componente	Tecnologia	Finalidade
Modelo ML	Scikit-Learn (XGBoost)	Predição de status de fumante
Backend	FastAPI + Uvicorn	API REST
Frontend	Streamlit	Interface Web
Serialização	Joblib (.pkl)	Persistência do modelo



Estrutura do Projeto

```
project-root/
|
├─ api/
|   ├── main.py
|   └─ requirements.txt
|
├─ app/
|   ├── app.py
|   └─ requirements.txt
|
├─ model_artifacts/
|   ├── smoking_model.pkl
|   ├── scaler.pkl
|   ├── label_encoder.pkl
|   └─ feature_names.pkl
|
├─ notebook/
|   └─ Cópia_de_Equipe_04_smoking_drinking_dataset.ipynb
|
└─ README.md
```



Pré-requisitos

Certifique-se de possuir:

- Python 3.10 ou superior
- pip
- Git

Downloads

- Python: <https://www.python.org/downloads/> (<https://www.python.org/downloads/>)
- Git: <https://git-scm.com/> (<https://git-scm.com/>)



Instalação

1. Clonar o repositório

```
git clone https://github.com/Rafaelsn11/smoking_drinking_dataset.git cd
smoking_drinking_dataset
```

2. Instalar dependências da API

```
cd api
pip install -r requirements.txt
```

3. Instalar dependências do Frontend

```
cd ../app
pip install -r requirements_streamlit.txt
```

4. Gerar os artefatos do modelo

Necessário apenas na primeira execução.

Abra o notebook:

```
Cópia_de_Equipe_04_smoking_drinking_dataset.ipynb
```

Execute todas as células em sequência.

Ao final serão gerados:

```
model_artifacts/
├─ smoking_model.pkl
├─ scaler.pkl
├─ label_encoder.pkl
└─ feature_names.pkl
```



Executando a Aplicação

A aplicação necessita de dois serviços executando simultaneamente.

Abra dois terminais.

Terminal 1 — Backend FastAPI

```
cd api
python -m uvicorn main:app --reload
```

API disponível em:

```
http://localhost:8000
```

Documentação Swagger:

```
http://localhost:8000/docs
```

Terminal 2 — Frontend Streamlit

```
cd app
python -m streamlit run app.py
```

Interface disponível em:

```
http://localhost:8501
```



Como Utilizar

1. Acesse:

```
http://localhost:8501
```

2. Preencha os dados biométricos do paciente:

- Personal Data
- Anthropometric Measurements
- Blood Pressure

- Lab Results

3. Os seguintes índices são calculados automaticamente:

- BMI (Body Mass Index)
- Atherogenic Index

4. Clique em:

Analisar Paciente

5. O sistema retornará:

- Classe prevista
- Percentual de confiança
- Distribuição de probabilidade para todas as classes



API Reference

Método	Endpoint	Descrição
GET	/	Health Check
GET	/features	Lista das features do modelo
POST	/predict	Predição do status de fumante
GET	/docs	Swagger UI

Exemplo de Requisição

POST /predict

```
{
  "age": 35,
  "height_cm": 175,
  "weight_kg": 80,
  "waist_cm": 85,
  "systolic": 120,
  "relaxation": 80,
  "fasting_blood_sugar": 95,
  "cholesterol": 180,
  "triglyceride": 120,
  "hdl": 55,
  "ldl": 100,
  "hemoglobin": 14.5,
  "serum_creatinine": 1.0,
  "ast": 20,
  "alt": 25,
  "gtp": 30
}
```

Exemplo de Resposta

```
{
  "prediction": "Never Smoked",
  "confidence": 92.4,
  "probabilities": {
    "Never Smoked": 0.924,
    "Former Smoker": 0.053,
    "Current Smoker": 0.023
  }
}
```



Troubleshooting

500 Internal Server Error

O scaler e o modelo devem possuir exatamente o mesmo número de features (19).

Execute novamente as células responsáveis pela geração dos artefatos.

InconsistentVersionWarning

Os arquivos `.pkl` foram gerados em uma versão diferente do Scikit-Learn.

Para corrigir:

```
pip install scikit-learn==1.4.2
```

API Offline no Streamlit

Verifique se o backend FastAPI está executando na porta 8000 antes de clicar em:

Analisar Paciente

ModuleNotFoundError

Instale as dependências em cada módulo:

```
cd api
pip install -r requirements.txt

cd ../app
pip install -r requirements.txt
```

model_artifacts não encontrado

Execute todas as células do notebook para gerar os arquivos:

model_artifacts/



Dataset

Korean National Health Insurance Service (NHIS)

Aproximadamente **1 milhão de registros** contendo indicadores biométricos e hábitos relacionados ao tabagismo.



Modelo Utilizado

- Random Forest Classifier
- Scikit-Learn
- Classificação Multiclasse

Classes previstas:

- Never Smoked
- Former Smoker
- Current Smoker



Equipe

Projeto acadêmico desenvolvido para estudo de Machine Learning aplicado à área da saúde.

Smoking Status Predictor

Dataset: Korean NHIS Smoking & Drinking

Modelo: XGBoost

2026